

Polypharmacy Drug-Drug Interaction (DDI) Prediction System

Microsoft AI Innovators Summer Internship Project – İrem Altın

1. Özet

Bu çalışma, birden fazla ilacın eş zamanlı kullanımında ortaya çıkabilecek olumsuz etkileşim riskini tahmin eden bir makine öğrenmesi sistemi sunmaktadır. TWOSIDES veri seti kullanılarak, ilaç çiftlerinin moleküler yapısından (Morgan Fingerprint) yola çıkan bir ikili sınıflandırma modeli geliştirilmiş; Logistic Regression, Random Forest ve XGBoost karşılaştırılmış, en yüksek Recall ve ROC-AUC değerlerini veren Logistic Regression nihai model olarak seçilmiştir. Sistem, ikili kombinasyon ayrıştırması yoluyla 10 ilaca kadar polifarmasi senaryolarını da değerlendirebilecek şekilde genişletilmiş ve Streamlit üzerinden interaktif bir uygulama olarak sunulmuştur.

2. Giriş

Polifarmasi, özellikle yaşlı ve kronik hasta popülasyonlarında hasta güvenliğini tehdit eden, klinik açıdan önlenemez bir risk kaynağıdır. Erken tahmin, reçete öncesi karar destek sistemlerine girdi sağlayabilir. Bu projenin girdi, çıktı ve görev tipi bilgisi aşağıdaki gibidir:

- Girdi: İlaçların kimyasal yapısı (SMILES gösterimi) ve kimlik bilgisi.
- Çıktı: İlaçların (10 ilaca kadar) birlikte kullanımında bir etkileşim olayı olup oluşmayacağı
- Görev tipi: Denetimli sınıflandırma (supervised classification).

3. Genel Sistem Yapısı

Geliştirilen sistem, Streamlit ile oluşturulan kullanıcı arayüzünde 10 adede kadar ilaç girişini desteklemektedir. Model, girilen tüm ilaçları kendi içinde ikili kombinasyonlara ayırarak analiz eder. Sistem, bu ikili çiftlerin her biri için ayrı ayrı etkileşim tahmini yürüterek geniş kapsamlı bir kombinasyon raporu sunar.

Dolayısıyla model, yüksek dereceli kombinasyonların (3'lü, 4'lü veya daha fazla ilacın aynı anda alınmasının) yarattığı sinerjik etkileri hesaplayamaz. Örneğin; sisteme girilen 3 ilacın kendi aralarındaki tüm ikili kombinasyonları (A-B, A-C, B-C) güvenli çıkabilir; fakat bu 3 ilaç aynı anda vücuda alındığında tamamen farklı ve öngörülemez bir yan etki tetiklenebilir. Model, veri setinin yapısı gereği bu tarz kolektif etkileşimleri tahmin etme yeteneğine sahip değildir.

Aşağıda, geliştirilen Streamlit arayüzü ve Logistic Regression tabanlı tahmin modelinin klinik doğruluğunu test etmek amacıyla, tıp literatüründe bir arada kullanılması son derece riskli olarak kabul edilen Warfarin, Aspirin ve Ibuprofen ilaçlarından oluşan 3'lü bir senaryo simüle edilmiştir.

Medication List Management

Select number of medications to analyze (2-10):

3

Medication #1

Enter Drug Name #1

Warfarin

✓ 'Warfarin' identified successfully.

Medication #2

Enter Drug Name #2

Ibuprofen

✓ 'Ibuprofen' identified successfully.

Medication #3

Enter Drug Name #3

Aspirin

✓ 'Aspirin' identified successfully.

Sistem yapısal olarak ikili (*pairwise*) etkileşimleri tahmin etmek üzere optimize edildiğinden, bu 3'lü kombinasyon arka planda izole edilerek 3 farklı ikili çift halinde analize tabi tutulmuştur.

Elde edilen aşağıdaki ekran görüntüsünde de görüleceği üzere model, TWOSIDES veri setinden öğrendiği kimyasal ve klinik öznitelikleri (SMILES girdileri üzerinden) başarıyla anlamlandırarak, klinik riskin ciddiyetini hassas bir şekilde ortaya koymuştur.

Klinik asistan desteği olarak Explainable AI Analysis eklentisi ile risk kararına nasıl vardığı SHAP modeliyle gösterilmiştir.

Analyze Interaction Risks

Interaction Risk Detected: Warfarin + Aspirin

Risk Status: HIGH RISK | Interaction Probability: 99.99%

> Explainable AI (SHAP) Analysis for Warfarin + Aspirin

Interaction Risk Detected: Warfarin + Ibuprofen

Risk Status: HIGH RISK | Interaction Probability: 99.98%

> Explainable AI (SHAP) Analysis for Warfarin + Ibuprofen

Interaction Risk Detected: Aspirin + Ibuprofen

Risk Status: HIGH RISK | Interaction Probability: 99.94%

> Explainable AI (SHAP) Analysis for Aspirin + Ibuprofen

4. Veri ve Kullanılan Yöntemler

4.1 Veri Seçimi


Literatürde DDI çalışmalarında sık kullanılan veri seti DrugBank kütüphanesidir. Fakat DrugBank'in akademik indirme programı Mayıs 2026'dan bu yana askıya alınmış durumda ve kısa vadede tekrar açılması beklenmiyor; bu nedenle proje TWOSIDES veri seti üzerinden yürütüldü.

TWOSIDES veri seti, PyTDC kütüphanesi üzerinden erişilmiş olup toplam 4.649.441 ilaç çifti kaydı içermektedir. Hesaplama kısıtları nedeniyle sınıf dengesi korunarak rastgele bir alt örneklem (N=200.000) seçilmiş ve tüm modelleme bu örneklem üzerinde gerçekleştirilmiştir.


4.2 Veri İşleme

Öncelikle veri kalitesi gözden geçirilmiş ve eksik ve yanlış girilmiş kayıtlar kontrol edilmiştir. EDA sonucunda boş veri ve tanımsız ilaç bulunmadığı gözlemlenmiştir.

Aşağıdaki En Sık Görülen İlk 20 Etkileşim Türünün frekans dağılımı incelendiğinde, sınıflar arasında keskin bir uçurum olmadığı ve frekansların yumuşak bir geçiş gösterdiği gözlemlenmiştir. Bu durum, model eğitilirken etkileşimler özelinde ciddi bir sınıf dengesizliği (class imbalance) yaşanmayacağını ve modelin bu sınıfları öğrenirken yanlılık (bias) geliştirmesinin minimumda kalacağını göstermektedir.



Öte yandan aşağıdaki İlaç Etkileşim Ağının Derece Dağılımı grafiği incelendiğinde veri setinin ölçeksiz ağ (scale-free network) yapısına sahip olduğunu görülmektedir. Az sayıdaki muhtemelen popüler olan ilaçlar çok yüksek sayıda (500+) etkileşime sahipken, ilaçların büyük bir çoğunluğu daha az etkileşime sahiptir. Bu durum, girdi bazında bir dengesizlik yaratmaktadır. Model, çok sık etkileşime giren (yüksek dereceli) ilaçların kimyasal yapılarını çok daha kolay ve başarılı öğrenecektir çünkü onlarla ilgili çok fazla veri vardır. Ancak çok az etkileşime giren ilaçlar için elinde az örnek olacağından, model bu nadir ilaçların etkileşimlerini tahmin etmekte zorlanabilir.



Ardından her ilaç için RDKit kütüphanesi kullanılarak Morgan Fingerprint çıkarılmıştır.


TWOSIDES veri setinde sadece gerçekten etkileşimi olan ilaç çiftleri vardır fakat bir modelin etkileşim var/yok ayrımını öğrenebilmesi için hem pozitif hem negatif örnekler gereklidir. Negatif örnek olmadan model her zaman "etkileşim var" demeyi öğrenir çünkü hiç yok örneği görmemiştir.

Veri setinde negatif örnek bulunmadığı için literatürdeki standart yaklaşım baz alınarak negatif örnekler üretilir. Eğer iki ilaç veri setinde hiç birlikte geçmiyorsa, muhtemelen aralarında bilinen bir etkileşim yoktur. Bu varsayım %100 doğru değildir, sadece pratik bir yaklaşımdır ve aslen bir sınırlamadır. Negatif örnekler, pozitif:negatif oranı 1:1 olacak şekilde sentetik olarak üretilmiştir.

Ve son olarak iki ilacın fingerprint'leri concatenation (uç uca ekleme) yöntemiyle 4096 boyutlu tek bir vektörde birleştirilmiştir. Literatürde DDI tahmininde en sık kullanılan ve bilgi kaybını en aza indiren yöntem olduğu için concatenation tercih edilmiştir.

5. Modelleme

En doğru sonucu almak adına veri seti üç farklı sınıflandırma modeli (Logistic Regression, Random Forest Classifier, XGBoost) üzerinde test edilmiş ve en yüksek Recall skorunu veren model baseline olarak kabul edilmiştir. Üç model de aynı train/test bölünmesi (0.8 / 0.2) ve concatenation ile birleştirilmiş fingerprint verisi kullanılarak karşılaştırılmıştır. Model seçiminde kaçırılan bir etkileşimin (False Negative) klinik maliyeti yüksek olduğu için öncelikli kriter Recall olsa da Precision ve ROC-AUC değerleri de göz önünde bulundurulmuştur.




En yüksek Recall (0.93) ve ROC-AUC (0.98) değerlerini Logistic Regression vermiş, XGBoost (Recall: 0.91) ve Random Forest (Recall: 0.83) onu izlemiştir. Bu sonuç, Morgan Fingerprint temsilinin yüksek boyutlu ve seyrek (sparse) ikili yapısının, ağaç tabanlı modellerin aradığı karmaşık ilişkilerden çok doğrusal bir ilişkiye daha yatkın olabileceğini düşündürmektedir. Bu nedenle nihai model olarak Logistic Regression seçilmiştir.

Ayrıca seçilen modele yapılan yanlış pozitif analizi sonucunda da modelin, negatif (etkileşimsiz) test örneklerinin %91.45'ini doğru sınıflandırırken, %8.55'lik bir yanlış pozitif sınıflandırma oranına sahip olduğu görülmektedir. Bu sonuç klinik karar destek sistemlerinde beklenen bir hata payıdır ve modelin recall'a öncelik veren (false negative maliyetinin false positive'ten yüksek kabul edildiği) tasarım felsefesiyle tutarlıdır.

6. SHAP Yorumlanabilirliği

Modelin klinik bağlamda güvenilir kabul edilebilmesi için tahminlerinin açıklanabilir olması önemlidir. SHAP (SHapley Additive exPlanations) yöntemi kullanılarak, modelin bireysel tahminlerini hangi fingerprint bit'lerinin ne yönde etkilediği analiz edilmiştir. Fingerprint bit'lerinin doğrudan kimyasal alt yapı isimlerine karşılık gelmemesi, bu yorumlamanın bir sınırlamasıdır.



Yukarıdaki waterfall grafiği, rastgele seçilen bir test örneği için modelin kararını adım adım gösteriyor. $E[f(X)] = -0.998$, modelin tüm veri seti genelindeki ortalama tahminini (referans noktası) gösterir. Yani model hiçbir şey bilmeden tahmin yaptığında bu skoru verirdi. Bu spesifik örnek için model $f(x) = 4.385$ skorunu üretmiştir. Ortalamanın belirgin şekilde üzerinde, yani model bu çiftin etkileşme olasılığını güçlü şekilde desteklemektedir. Birkaç azaltıcı(mavi) özelliğe rağmen, çok sayıda küçük pozitif(kırmızı) katkının toplamda baskın gelmesi, modeli bu çifti yüksek riskli olarak sınıflandırmaya yöneltmiştir.

Bu ilaç çiftinde, Feature 561'in yokluğu (0 = Feature 561) tek başına en güçlü negatif etkiyi yapmış (-2.34) yani bu bit'in olmaması, riski bir miktar azaltıyor. Ama buna rağmen, 8 farklı bit'in varlığı ve özellikle 4087 diğer özelliğin toplam etkisi (+3.01) bu tek negatif etkiyi fazlasıyla bastırmış. Sonuç olarak model, ortalamanın (-0.998) çok üzerinde, 4.385'lik yüksek bir risk skoru üretmiş yani bu iki ilacın etkileşme olasılığını güçlü şekilde destekliyor.

7. Sınırlamalar

- DrugBank'in akademik erişiminin askıya alınmış olması
- RAM kısıtları nedeniyle tüm veri yerine 200.000 satırlık alt örneklem kullanılması
- Sentetik negatif örnekleme yönteminin "veri setinde yer almayan çift = etkileşimsiz" varsayımına dayanması
- Emergent (üçlü ve üzeri) ilaç etkileşimlerinin modellenememesi
- Fingerprint bit'lerinin doğrudan kimyasal yorumlanabilirliğinin sınırlı olması

8. Sonuç

Bu çalışma, TWOSIDES veri seti ve klasik makine öğrenmesi yöntemleriyle, klinik açıdan önemli bir hasta güvenliği problemine (polifarmasi) yönelik açıklanabilir ve genişletilebilir bir tahmin sistemi ortaya koymuştur.

Üç model arasında en yüksek Recall ve ROC-AUC değerlerini veren Logistic Regression'ın seçilmesi, yüksek boyutlu ve seyrek fingerprint verisinde doğrusal modellerin ağaç tabanlı modellere üstünlük gösterebileceğini ortaya koyan dikkat çekici bir bulgu olmuştur.